

## Домашнее задание №2

Иванов Вячеслав, группа 699

6 октября 2018 г.

# Оглавление

1	Найти градиент по $\mathbf{U}$ и по $\mathbf{V}$ функции $J(\mathbf{U}, \mathbf{V}) := \ \mathbf{UV} - \mathbf{Y}\ _F^2 + \frac{\lambda}{2}(\ \mathbf{U}\ _F^2 + \ \mathbf{V}\ _F^2)$	3
1.1	$\frac{dJ(\mathbf{U}, \mathbf{V})}{d\mathbf{V}}$	3
1.2	$\frac{dJ(\mathbf{U}, \mathbf{V})}{d\mathbf{U}}$	4
2	Найти градиент и гессиан функции $f(\mathbf{w}) = \sum_{i=1}^m \log(1 + e^{-y_i \mathbf{w}^T \mathbf{x}_i})$ , где $x_i \in \mathbb{R}^n$ , $y_i \in \mathbb{R}$	4
3	Найти матрицу Якоби для функции $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ , $f_j(\mathbf{w}) := \frac{e^{w_j}}{\sum_{k=1}^n e^{w_k}}$	4
4	Доказать тождество Шермана-Моррисона-Вудбери	5
5	Найти градиент отношения Релея для заданной матрицы $\mathbf{A} \in \mathbf{S}^n$ . Исследовать связь между отношением Релея и задачей поиска собственного вектора, соответствующего максимальному собственному значению.	5
6	Найти градиенты функций от собственных значений матрицы:	6
6.1	$f(\mathbf{X}) := \sum_{i=1}^n \lambda_i(\mathbf{X})$	6
6.2	$f(\mathbf{X}) := \prod_{i=1}^n \lambda_i(\mathbf{X})$	6
7	Найти градиент логарифма функции правдоподобия для многомерного нормального распределения по вектору средних значений и по матрице ковариаций	7

**1** Найти градиент по  $\mathbf{U}$  и по  $\mathbf{V}$  функции  $J(\mathbf{U}, \mathbf{V}) := \|\mathbf{UV} - \mathbf{Y}\|_F^2 + \frac{\lambda}{2}(\|\mathbf{U}\|_F^2 + \|\mathbf{V}\|_F^2)$

*Решение.*

**Определение.**  $f : \mathbb{R}^{n \times m} \rightarrow \mathbb{R} \implies \frac{df(\mathbf{X})}{d\mathbf{X}} := \left[ \frac{\partial f}{\partial x_{ij}}(\mathbf{X}) \right]_{\substack{1 \leq i \leq n \\ 1 \leq j \leq m}}$

**Утверждение 1.**  $\|\mathbf{X}\|_F^2 = \text{tr}(\mathbf{X}^T \mathbf{X})$

**Утверждение 2.**  $\frac{d \text{tr}(\mathbf{X}^T \mathbf{A} \mathbf{X})}{d\mathbf{X}} = (\mathbf{A} + \mathbf{A}^T) \mathbf{X}$ , в частности  $\frac{d\|\mathbf{X}\|_F^2}{d\mathbf{X}} = 2\mathbf{X}$ ,  $\frac{d\|\mathbf{XY}\|_F^2}{d\mathbf{Y}} = 2\mathbf{X}^T \mathbf{XY}$ .

**Утверждение 3** (Свойства следа).

- $\text{tr}(A_1 A_2 \dots A_n) = \text{tr}(A_n A_1 \dots A_{n-1})$  (в частности,  $\text{tr}(AB) = \text{tr}(BA)$ )
- $\text{tr}(A^T A) = \text{tr}(AA^T)$

**Утверждение 4.**

$$\frac{d \text{tr}(\mathbf{A} \mathbf{X} \mathbf{B})}{d\mathbf{X}} = \mathbf{A}^T \mathbf{B}^T$$

*Доказательство.* Доказано на семинаре от 11.09.2018. □

*Доказательство.*

$$\begin{aligned} [\mathbf{X}^T \mathbf{A} \mathbf{X}]_{lm} &= \sum_{i=1}^n x_{il} \sum_{j=1}^n a_{ij} x_{jm} = \sum_{i=1}^n \sum_{j=1}^n x_{il} a_{ij} x_{jm} \\ \text{tr}(\mathbf{X}^T \mathbf{A} \mathbf{X}) &= \sum_{l=1}^n [\mathbf{X}^T \mathbf{A} \mathbf{X}]_{ll} = \sum_{l=1}^n \sum_{i=1}^n \sum_{j=1}^n x_{il} a_{ij} x_{jl} \end{aligned}$$

$$\frac{d \text{tr}(\mathbf{X}^T \mathbf{A} \mathbf{X})}{dx_{lm}} = \left( \sum_{i=1}^n \sum_{j=1}^n x_{im} a_{ij} x_{jl} \right)'_{lm} = \sum_{j=1}^n a_{lj} x_{jm} + \sum_{i=1}^n x_{im} a_{il} = \sum_{i=1}^n (a_{li} + a_{il}) x_{im} = [(A + A^T) \mathbf{X}]_{lm}$$

□

### 1.1 $\frac{dJ(\mathbf{U}, \mathbf{V})}{d\mathbf{V}}$

Во первых, по утверждению 2:  $\frac{d\|\mathbf{V}\|_F^2}{d\mathbf{V}} = 2\mathbf{V}$ .

Во вторых, по свойствам следа:

$$\begin{aligned} \|\mathbf{UV} - \mathbf{Y}\|_F^2 &= \text{tr}((\mathbf{UV} - \mathbf{Y})^T (\mathbf{UV} - \mathbf{Y})) = \\ &= \|\mathbf{UV}\|_F^2 + \|\mathbf{Y}\|_F^2 - \text{tr}(\mathbf{Y}^T \mathbf{UV}) - \text{tr}(\mathbf{V}^T \mathbf{U}^T \mathbf{Y}) = \\ &= \|\mathbf{UV}\|_F^2 + \|\mathbf{Y}\|_F^2 - 2 \cdot \text{tr}(\mathbf{Y}^T \mathbf{UV}) \end{aligned}$$

Откуда по утверждению 2 получаем, что:

$$\frac{d\|\mathbf{UV}\|_F^2}{d\mathbf{V}} = 2\mathbf{U}^T \mathbf{UV}$$

Осталось посчитать  $\frac{d\text{tr}(\mathbf{Y}^T \mathbf{UV})}{d\mathbf{V}}$ . По свойствам следа,  $\text{tr}(\mathbf{Y}^T \mathbf{UV}) = \text{tr}(\mathbf{UVY}^T)$ . Отсюда по утверждению 3 сразу получаем, что:

$$\frac{d\text{tr}(\mathbf{Y}^T \mathbf{UV})}{d\mathbf{V}} = \mathbf{U}^T \mathbf{Y}$$

Собирая промежуточные результаты в итоговое выражение, получаем, что:

$$\frac{dJ(\mathbf{U}, \mathbf{V})}{d\mathbf{V}} = 2\mathbf{U}^T (\mathbf{UV} - \mathbf{Y}) + \lambda \mathbf{V}$$

## 1.2 $\frac{dJ(\mathbf{U}, \mathbf{V})}{d\mathbf{U}}$

И вновь, по утверждению 2:  $\frac{d\|\mathbf{U}\|_F^2}{d\mathbf{U}} = 2\mathbf{U}$ .

По утверждению 3 сразу получаем, что:

$$\frac{d\text{tr}(\mathbf{Y}^T \mathbf{U} \mathbf{V})}{d\mathbf{U}} = \mathbf{Y} \mathbf{V}^T$$

Из свойств следа (из второго, если быть точным) и утверждения 2 получаем, что:

$$\begin{aligned} \|\mathbf{U} \mathbf{V}\|_F^2 &= \text{tr}(\mathbf{V}^T \mathbf{U}^T \mathbf{U} \mathbf{V}) = \text{tr}(\mathbf{U} \mathbf{V} \mathbf{V}^T \mathbf{U}^T) = \|\mathbf{V}^T \mathbf{U}^T\|_F^2 \\ \Rightarrow \frac{d\|\mathbf{U} \mathbf{V}\|_F^2}{d\mathbf{U}} &= \left( \frac{d\|\mathbf{V}^T \mathbf{U}^T\|_F^2}{d\mathbf{U}^T} \right)^T = (2\mathbf{V} \mathbf{V}^T \mathbf{U}^T)^T = 2\mathbf{U} \mathbf{V} \mathbf{V}^T \end{aligned}$$

Собирая промежуточные результаты в итоговое выражение, получаем, что:

$$\frac{dJ(\mathbf{U}, \mathbf{V})}{d\mathbf{U}} = 2(\mathbf{U} \mathbf{V} - \mathbf{Y}) \mathbf{V}^T + \lambda \mathbf{U}$$

□

## 2 Найти градиент и гессиан функции $f(\mathbf{w}) = \sum_{i=1}^m \log(1 + e^{-y_i \mathbf{w}^T \mathbf{x}_i})$ , где $x_i \in \mathbb{R}^n$ , $y_i \in \mathbb{R}$

Решение.

$$\frac{\partial f}{\partial w_j}(\mathbf{w}) = \sum_{i=1}^m \frac{-y_i x_{ij} e^{-y_i \mathbf{w}^T \mathbf{x}_i}}{1 + e^{-y_i \mathbf{w}^T \mathbf{x}_i}}$$

Обозначим  $\frac{-y_i e^{-y_i \mathbf{w}^T \mathbf{x}_i}}{1 + e^{-y_i \mathbf{w}^T \mathbf{x}_i}}$  через  $\theta_i(\mathbf{w})$ . Тогда  $\nabla f(\mathbf{w}) = \mathbf{X}^T \theta$ , где  $\mathbf{X} \in \mathbb{R}^{m \times n}$  — матрица, строками которой являются векторы  $\mathbf{x}_i$ .

Далее,

$$\begin{aligned} \frac{\partial^2 f}{\partial w_i \partial w_j}(\mathbf{w}) &= \sum_{k=1}^m \left( \frac{-y_k x_{kj} e^{-y_k \mathbf{w}^T \mathbf{x}_k}}{1 + e^{-y_k \mathbf{w}^T \mathbf{x}_k}} \right)'_i = \sum_{k=1}^m \left( \frac{y_k^2 e^{-y_k \mathbf{w}^T \mathbf{x}_k}}{1 + e^{-y_k \mathbf{w}^T \mathbf{x}_k}} - \left( \frac{-y_k e^{-y_k \mathbf{w}^T \mathbf{x}_k}}{1 + e^{-y_k \mathbf{w}^T \mathbf{x}_k}} \right)^2 \right) x_{ki} x_{kj} = \\ &= \sum_{k=1}^m \frac{y_k^2 e^{-y_k \mathbf{w}^T \mathbf{x}_k}}{1 + e^{-y_k \mathbf{w}^T \mathbf{x}_k}} \left( 1 - \frac{e^{-y_k \mathbf{w}^T \mathbf{x}_k}}{1 + e^{-y_k \mathbf{w}^T \mathbf{x}_k}} \right) x_{ki} x_{kj} = \\ &= \sum_{k=1}^m \frac{y_k^2 e^{-y_k \mathbf{w}^T \mathbf{x}_k}}{(1 + e^{-y_k \mathbf{w}^T \mathbf{x}_k})^2} x_{ki} x_{kj} \end{aligned}$$

Если положить  $\psi_k(\mathbf{w}) := \frac{y_k^2 e^{-y_k \mathbf{w}^T \mathbf{x}_k}}{(1 + e^{-y_k \mathbf{w}^T \mathbf{x}_k})^2}$ , то в матричном виде выражение можно переписать так:

$$\mathbf{H}(f)(\mathbf{w}) = \mathbf{X}^T \text{diag}(\psi_1(\mathbf{w}), \dots, \psi_m(\mathbf{w})) \mathbf{X}$$

□

## 3 Найти матрицу Якоби для функции $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ , $f_j(\mathbf{w}) := \frac{e^{w_j}}{\sum_{k=1}^n e^{w_k}}$

Утверждение 5.

$$\mathbf{J}(f)(\mathbf{w}) = \text{diag}(f_1, \dots, f_n)(\mathbf{w}) - \mathbf{f}(\mathbf{w})(\mathbf{f}(\mathbf{w}))^T$$

Доказательство.

$$\begin{aligned}\frac{\partial f_l}{\partial \mathbf{w}_l}(\mathbf{w}) &= \frac{e^{w_l}}{\sum_{k=1}^n e^{w_k}} - \frac{e^{2w_l}}{(\sum_{k=1}^n e^{w_k})^2} = \frac{e^{w_l}(\sum_{k \neq l} e^{w_k})}{(\sum_{k=1}^n e^{w_k})^2} \\ \frac{\partial f_l}{\partial \mathbf{w}_m}(\mathbf{w}) &= -\frac{e^{w_l+w_m}}{(\sum_{k=1}^n e^{w_k})^2}, \quad l \neq m\end{aligned}$$

В матричной записи:

$$\mathbf{J}(\mathbf{f})(\mathbf{w}) = \mathbf{f}(\mathbf{w})(\mathbf{f}(\mathbf{w}))^T - \text{diag}(f_1, \dots, f_n)(\mathbf{w})$$

□

## 4 Доказать тождество Шермана-Моррисона-Вудбери

Утверждение 6.

$$\begin{aligned}(\mathbf{A} + \mathbf{UCV})^{-1} &= \mathbf{A}^{-1} - \mathbf{A}^{-1}\mathbf{U}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})^{-1}\mathbf{VA}^{-1} \\ \mathbf{A} \in \mathbb{R}^{n \times n}, \quad \mathbf{U} \in \mathbb{R}^{n \times m}, \quad \mathbf{C} \in \mathbb{R}^{m \times m}, \quad \mathbf{V} \in \mathbb{R}^{m \times n}\end{aligned}$$

Доказательство.

$$\begin{aligned}(\mathbf{A} + \mathbf{UCV})(\mathbf{A}^{-1} - \mathbf{A}^{-1}\mathbf{U}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})^{-1}\mathbf{VA}^{-1}) &= \\ = (\mathbf{E} + \mathbf{UCVA}^{-1})(\mathbf{E} - \mathbf{U}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})^{-1}\mathbf{VA}^{-1}) &= \\ = \mathbf{E} + \mathbf{UCVA}^{-1} - (\mathbf{E} + \mathbf{UCVA}^{-1})\mathbf{U}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})^{-1}\mathbf{VA}^{-1} &= \\ = \mathbf{E} + \mathbf{UCVA}^{-1} - \mathbf{UC}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})^{-1}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})\mathbf{VA}^{-1} &= \\ = \mathbf{E} &\end{aligned}$$

$$\begin{aligned}(\mathbf{A}^{-1} - \mathbf{A}^{-1}\mathbf{U}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})^{-1}\mathbf{VA}^{-1})(\mathbf{A} + \mathbf{UCV}) &= \\ = (\mathbf{E} - \mathbf{A}^{-1}\mathbf{U}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})^{-1}\mathbf{V})(\mathbf{E} + \mathbf{A}^{-1}\mathbf{UCV}) &= \\ = \mathbf{E} + \mathbf{A}^{-1}\mathbf{UCV} - \mathbf{A}^{-1}\mathbf{U}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})^{-1}\mathbf{V}(\mathbf{E} + \mathbf{A}^{-1}\mathbf{UCV}) &= \\ = \mathbf{E} + \mathbf{A}^{-1}\mathbf{UCV} - \mathbf{A}^{-1}\mathbf{U}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})^{-1}(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U})\mathbf{CV} &= \\ = \mathbf{E} &\end{aligned}$$

□

**5 Найти градиент отношения Релея для заданной матрицы  $\mathbf{A} \in S^n$ . Исследовать связь между отношением Релея и задачей поиска собственного вектора, соответствующего максимальному собственному значению.**

**Определение.** *Отношением Релея* для заданной матрицы  $\mathbf{A} \in S^n$  называют выражение вида:

$$R(\mathbf{x}|\mathbf{A}) := \frac{\mathbf{x}^T \mathbf{A} \mathbf{x}}{\mathbf{x}^T \mathbf{x}}$$

**Утверждение 7.** Собственный вектор, соответствующий максимальному собственному значению матрицы  $\mathbf{A}$ , максимизирует отношение Релея для этой матрицы.

*Доказательство.*

Перепишем отношение Релея в бескоординатном виде через скалярное произведение:

$$R(\mathbf{x}|\mathbf{A}) = \frac{(\mathbf{x}, \mathbf{Ax})}{(\mathbf{x}, \mathbf{x})} = \frac{(\mathbf{x}, \mathbf{Ax})}{\|\mathbf{x}\|_2^2} = \left( \frac{\mathbf{x}}{\|\mathbf{x}\|_2}, \mathbf{A} \frac{\mathbf{x}}{\|\mathbf{x}\|_2} \right)$$

Из такой записи видно, что отношение Релея есть  $(\mathbf{y}, \mathbf{Ay})$  для  $\mathbf{y}$ , лежащих на единичной сфере. На семинаре обсуждалось, что для операторов, порождающих ортонормированный базис из собственных векторов (к таковым относятся эрмитовы, подмножеством которых является  $S^n$ ), данный функционал на единичной сфере достигает максимума на собственном векторе, принадлежащем максимальному собственному значению.  $\square$

**Утверждение 8.**  $\nabla R(\mathbf{x}|\mathbf{A}) = (\mathbf{A} - R(\mathbf{x}|\mathbf{A})\mathbf{E}) \frac{2\mathbf{x}}{\mathbf{x}^T \mathbf{x}}$

*Доказательство.*

$$\begin{aligned} \nabla \left( \frac{\mathbf{x}^T \mathbf{Ax}}{\mathbf{x}^T \mathbf{x}} \right) &= \frac{\nabla(\mathbf{x}^T \mathbf{Ax}) \mathbf{x}^T \mathbf{x} - (\mathbf{x}^T \mathbf{Ax}) \nabla(\mathbf{x}^T \mathbf{x})}{(\mathbf{x}^T \mathbf{x})^2} = \frac{2\mathbf{Ax}(\mathbf{x}^T \mathbf{x}) - \mathbf{x}^T \mathbf{Ax}(2\mathbf{x})}{(\mathbf{x}^T \mathbf{x})^2} = \\ &= 2 \frac{(\mathbf{x}^T \mathbf{x})\mathbf{A} - \mathbf{x}^T \mathbf{Ax}}{(\mathbf{x}^T \mathbf{x})^2} \mathbf{x} = \frac{2}{\mathbf{x}^T \mathbf{x}} \left( \mathbf{A} - \frac{\mathbf{x}^T \mathbf{Ax}}{\mathbf{x}^T \mathbf{x}} \mathbf{E} \right) \mathbf{x} = (\mathbf{A} - R(\mathbf{x}|\mathbf{A})\mathbf{E}) \frac{2\mathbf{x}}{\mathbf{x}^T \mathbf{x}} \end{aligned}$$

$\square$

## 6 Найти градиенты функций от собственных значений матрицы:

**6.1**  $f(\mathbf{X}) := \sum_{i=1}^n \lambda_i(\mathbf{X})$

**Утверждение 9.** След матрицы инвариантен относительно смены базиса.

*Доказательство.* Пусть  $\mathbf{C}$  — матрица перехода. По свойству следа:

$$\text{tr}(\mathbf{CXC}^{-1}) = \text{tr}(\mathbf{C}^{-1}\mathbf{CX}) = \text{tr}(\mathbf{X})$$

$\square$

**Утверждение 10.**  $f(\mathbf{X}) = \text{tr}(\mathbf{X})$ .

*Доказательство.*

Равенство верно по определению, если  $\mathbf{X}$  приведена к Жордановой форме.

Оно является тождеством в силу предыдущего утверждения.  $\square$

**Утверждение 11.**  $\nabla f(\mathbf{X}) = \mathbf{E}$

*Доказательство.*

Тривиально следует из определения матричной производной скалярной функции.  $\square$

**6.2**  $f(\mathbf{X}) := \prod_{i=1}^n \lambda_i(\mathbf{X})$

**Утверждение 12.** Определитель матрицы инвариантен относительно смены базиса.

*Доказательство.* Тривиально следует из мультипликативности определителя и выражения для определителя обратной матрицы.  $\square$

**Утверждение 13.**  $f(\mathbf{X}) = \det(\mathbf{X})$ .

*Доказательство.*

Равенство верно по определению, если  $\mathbf{X}$  приведена к Жордановой форме.

Оно является тождеством в силу предыдущего утверждения.  $\square$

**Утверждение 14.**

$$\nabla \det(\mathbf{X}) = \mathbf{C}(\mathbf{X})$$

где  $\mathbf{C}(\mathbf{X}) = [(-1)^{i+j} M_{ij}]_{\substack{1 \leq i \leq n \\ 1 \leq j \leq m}}$ , а  $M_{ij}$  — дополнительный минор для позиции  $x_{ij}$ .

*Доказательство.* Доказано на семинаре. □

## 7 Найти градиент логарифма функции правдоподобия для многомерного нормального распределения по вектору средних значений и по матрице ковариаций

**Определение.** Функция правдоподобия для многомерного нормального распределения:

$$p(\mathbf{X}|\mu, \Sigma) = \prod_{i=1}^N \frac{1}{(2\pi)^{n/2} \sqrt{\det \Sigma}} \exp \left( -\frac{1}{2} (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) \right), \quad \mathbf{x}_i \in \mathbb{R}^n$$

**Утверждение 15.**  $\frac{\partial}{\partial \mathbf{A}} \text{tr}(\mathbf{A}^{-1} \mathbf{B}) = -(\mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1})^T$

**Утверждение 16.**  $\frac{\partial \log p(\mathbf{X}|\mu, \Sigma)}{\partial \mu} = \sum_{i=1}^N \Sigma^{-1} (\mathbf{x}_i - \mu)$

*Доказательство.*

$$\begin{aligned} \frac{\partial \log p(\mathbf{X}|\mu, \Sigma)}{\partial \mu} &= \frac{\partial}{\partial \mu} \sum_{i=1}^N \log \left[ \frac{1}{(2\pi)^{n/2} \sqrt{\det \Sigma}} \exp \left( -\frac{1}{2} (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) \right) \right] = \\ &= \frac{\partial}{\partial \mu} \left( -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) \right) = \\ &= -\frac{1}{2} \frac{\partial}{\partial \mu} \sum_{i=1}^n (\mathbf{x}_i^T \Sigma^{-1} \mathbf{x}_i - \mu^T \Sigma^{-1} \mathbf{x}_i - \mathbf{x}_i^T \Sigma^{-1} \mu + \mu^T \Sigma^{-1} \mu) = \\ &= \sum_{i=1}^N \Sigma^{-1} (\mathbf{x}_i - \mu) \end{aligned}$$

□

**Утверждение 17.**  $\frac{\partial \log p(\mathbf{X}|\mu, \Sigma)}{\partial \Sigma} = -\frac{1}{2} (N \Sigma^{-1} - \Sigma^{-1} (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^T \Sigma^{-1})$

*Доказательство.*

$$\begin{aligned} \frac{\partial \log p(\mathbf{X}|\mu, \Sigma)}{\partial \Sigma} &= \frac{\partial}{\partial \Sigma} \sum_{i=1}^N \log \left[ \frac{1}{(2\pi)^{n/2} \sqrt{\det \Sigma}} \exp \left( -\frac{1}{2} (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) \right) \right] = \\ &= \frac{\partial}{\partial \Sigma} \left( -\frac{N}{2} \log \det \Sigma - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) \right) \end{aligned}$$

Перепишем сумму таким образом, чтобы можно было воспользоваться утверждением 15:

$$(\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) = \text{tr} (\Sigma^{-1} (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^T)$$

Тогда:

$$\begin{aligned} \frac{\partial}{\partial \Sigma} (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) &= -(\Sigma^{-1} (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^T \Sigma^{-1})^T = \\ &= -\Sigma^{-1} (\mathbf{x}_i - \mu) (\mathbf{x}_i - \mu)^T \Sigma^{-1} \end{aligned}$$

Т.к. матрица ковариаций симметрична.

Также, по правилу дифференцирования сложной функции получаем :

$$\frac{d}{d\Sigma} \log \det \Sigma = \frac{1}{\det \Sigma} \frac{d \det \Sigma}{d\Sigma} = \frac{C(\Sigma)}{\det \Sigma} = \frac{(\det \Sigma) \Sigma^{-T}}{\det \Sigma} = \Sigma^{-T} = \Sigma^{-1}$$

Итого получаем, что:

$$\frac{\partial \log p(\mathbf{X}|\mu, \Sigma)}{\partial \Sigma} = -\frac{1}{2}(N\Sigma^{-1} - \Sigma^{-1}(\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^T \Sigma^{-1})$$

□